ĐẠI HỌC KINH TẾ QUỐC DÂN

TRƯỜNG CÔNG NGHỆ



BÁO CÁO

HỌC THỐNG KÊ

Đề tài:

DỰ ĐOÁN VỠ NỢ KHOẢN VAY TRÊN DỮ LIỆU LENDING CLUB

Predicting Loan Default on Lending Club Data

Sinh viên:	**PHÙNG THỊ THU TRANG**
Mã sinh viên:	[MSSV]
Lớp:	DS66B
Giảng viên hướng dẫn:	[Tên giảng viên]

Hà Nội, [tháng, năm]

Lời cam đoan

Tôi là **PHÙNG THỊ THU TRANG**, mã sinh viên [MSSV], hiện đang theo học tại lớp DS66B. Dưới sự hướng dẫn của **[Tên giảng viên]**, tôi đã thực hiện và hoàn thành đề tài *"Dự đoán vỡ nợ khoản vay trên dữ liệu Lending Club"*.

Tôi xin cam đoan toàn bộ nội dung trình bày là kết quả học tập và làm việc nghiêm túc của bản thân. Mọi con số trong bài đều do code chạy trên dữ liệu thật in ra; mọi thông tin trích dẫn và tài liệu tham khảo đã được liệt kê đầy đủ trong phần Tài liệu tham khảo.

Tôi hoàn toàn chịu trách nhiệm về tính trung thực và nội dung của đề tài này.

Hà Nội, [ngày tháng năm]
Người cam đoan

PHÙNG THỊ THU TRANG

Lời nói đầu

Hoạt động cho vay luôn phải trả lời một câu hỏi trước khi giải ngân: *người vay này có khả năng không trả được nợ hay không?* Lending Club công bố dữ liệu các khoản vay thật, cho phép nghiên cứu câu hỏi này trên quy mô lớn thay vì dữ liệu mẫu.

Đề tài xây dựng quy trình thống kê hoàn chỉnh: định nghĩa nhãn, chia dữ liệu theo thời gian, chống rò rỉ thông tin, so sánh các mô hình với mốc `sub_grade` có sẵn, và báo cáo trung thực cả những kết quả không như kỳ vọng.

Em xin cảm ơn **[Tên giảng viên]** đã hướng dẫn trong suốt môn học. Do hạn chế về thời gian và kiến thức, bài không tránh khỏi thiếu sót; em mong nhận được góp ý của thầy cô.

Mở đầu: Đặt vấn đề

Lending Club là nền tảng cho vay ngang hàng (peer-to-peer) của Mỹ. Mỗi khoản vay kết thúc ở một trong hai trạng thái: Charged Off (vỡ nợ, nhãn 1) hoặc Fully Paid (trả đủ, nhãn 0).

Câu hỏi: nếu chỉ dùng thông tin biết được lúc xét duyệt, ta xếp hạng rủi ro người vay tốt đến đâu, và mô hình có hơn `sub_grade` (A1–G5) của chính nền tảng không?

Thách thức

- **Rò rỉ dữ liệu**: nhiều cột trong 151 cột chỉ có sau khi vay
- **Thời gian**: tỷ lệ vỡ nợ trôi từ 13.7% lên 14.8%
- **Kiểm duyệt**: khoản vay mới chưa có kết cục
- **Đối thủ có sẵn**: `sub_grade` đã là một mô hình rủi ro

Bài toán

Đầu vào: thông tin người vay và hồ sơ tín dụng lúc xét duyệt
Đầu ra: điểm rủi ro $p \in [0, 1]$ (xác suất vỡ nợ) để xếp hạng
Nhãn: Charged Off $= 1$, Fully Paid $= 0$

Nguyên tắc số một

Không dùng dữ liệu phát sinh sau khi duyệt vay.

Mở đầu: Mục tiêu và đóng góp

Mục tiêu: ước lượng trung thực thông tin lúc xét duyệt bổ sung được bao nhiêu so với `sub_grade` khi xếp hạng rủi ro vỡ nợ.

Đóng góp chính

- Quy trình chống rò rỉ: chỉ dùng cột biết lúc xét duyệt, có bằng chứng bằng AUC từng cột
- Chia Out-of-Time 70/15/15 trên khoản vay 36 tháng đã đáo hạn
- Pipeline chỉ học trên train (điền trung vị, chuẩn hóa, one-hot)
- So sánh Baseline, Logistic L2, Decision Tree, Random Forest, HistGB bằng ROC-AUC, Gini, KS và bootstrap
- Hai thí nghiệm mở rộng: bỏ `sub_grade`, thẻ điểm 12 biến
- Báo cáo trung thực cả kết quả không như kỳ vọng

Mở đầu: Bố cục

Chương 1. Mở đầu Đặt vấn đề, mục tiêu và đóng góp, bố cục.

Chương 2. Dữ liệu và tiền xử lý Từ điển 151 cột, nhãn mục tiêu, lọc và chia theo thời gian, làm sạch, chọn và tạo đặc trưng (Bước 1–6).

Chương 3. Mô hình hóa và đánh giá Huấn luyện 5 mô hình, kiểm định bootstrap, đánh giá test một lần (Bước 7–8).

Chương 4. Thí nghiệm mở rộng Bỏ `sub_grade`; thẻ điểm 12 biến; phân tầng rủi ro trên test (Thí nghiệm 1–3).

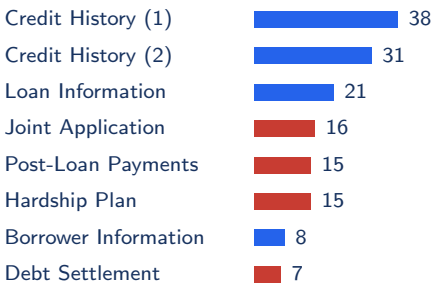
Kết luận Kết luận chung và hướng phát triển.

Tài liệu tham khảo

Hiểu dữ liệu: Từ điển dữ liệu

151 cột chia thành 8 nhóm, mỗi cột gắn nhãn: có biết lúc nộp đơn không?

SỐ CỘT MỖI NHÓM



Màu đỏ = nhóm chỉ có dữ liệu sau khi khoản vay bắt đầu

NHÃN THỜI ĐIỂM

103 Yes: biết lúc nộp đơn

41 No: sau khi vay hoặc là mã định danh

7 Uncertain: chưa rõ thời điểm

151 / 151

từ điển khớp đúng header file gốc

Nạp dữ liệu và định nghĩa nhãn mục tiêu

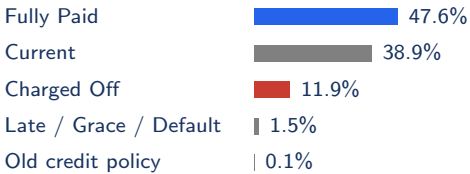
Chỉ khoản vay đã có kết cục cuối cùng mới có nhãn

2,260,701
dòng × 151 cột

1,345,310
dòng có nhãn

20.0%
tỷ lệ vỡ nợ (trong số có nhãn)

TRẠNG THÁI KHOẢN VAY (% TOÀN BỘ DÒNG)



nhãn 0 = Fully Paid · nhãn 1 = Charged Off · xám = bị loại (chưa có kết cục)

KỲ HẠN (ĐÃ ĐÁO HẠN, TỪ 2012)



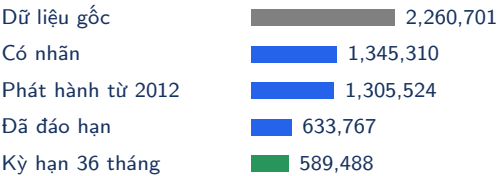
Chỉ giữ khoản 36 tháng để cả 3 tập có cùng một kỳ hạn.

CHƯƠNG 2 · BƯỚC 3 · NOTEBOOK 01

Lọc dữ liệu và chia Out-of-Time

Huấn luyện trên khoản vay cũ, kiểm tra trên khoản vay mới: 70 / 15 / 15 theo ngày

PHỄU LỌC (SỐ DÒNG)

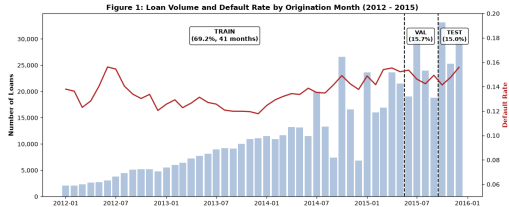


BA TẬP DỮ LIỆU

Train	408,188 69.2%	2012-01 → 2015-05 tỷ lệ vỡ nợ 13.7%
Val	92,631	2015-06 → 09 vỡ nợ 14.7%
Test	88,669	2015-10 → 12 vỡ nợ 14.8%

Quy tắc đáo hạn và phân chia theo thời gian

- **Đáo hạn**: tháng phát hành + kỳ hạn $\leq$ 2018-12
- Kiểm chứng: 99.6% khoản đã đáo hạn có kết cục, so với 42.4% khoản chưa đáo hạn
- **Vì sao từ 2012**: 44 cột bureau chỉ có dữ liệu từ 2012; trước 2012 chỉ chiếm 3.0% khoản có nhãn
- Sắp theo `issue_date`, cắt tại ngày ở vị trí 70% và 85%; một tháng chỉ nằm trong một tập
- Tỷ lệ vỡ nợ trôi lên $+1.1$ điểm: trôi dạt theo thời gian



Làm sạch dữ liệu: 6 quy tắc logic

Mỗi quy tắc kiểm tra từng dòng; cùng một quy tắc chạy trên train, val và test

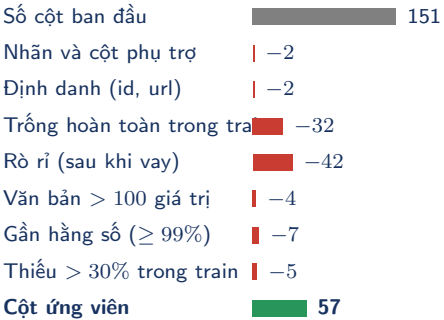
#	Quy tắc (kiểm tra)	Lý do	Xử lý
1	`annual_inc` ≤ 0	Thu nhập phải dương	Đặt thành thiếu
2	`loan_amnt` ≤ 0	Số tiền vay phải dương	Đặt thành thiếu
3	`dti` < 0 hoặc > 100	DTI phải trong 0–100	Đặt thành thiếu
4	`revol_util` > 100	Trên 100% có thể xảy ra; giá trị cực đoan là nhiễu	Cắt tại 102 (p99.9 của train)
5	`fico_low` $>$ `fico_high`	Cận dưới không vượt cận trên	Đặt cả hai thành thiếu
6	`earliest_cr_line` $>$ `issue_d`	Tài khoản đầu tiên phải mở trước khoản vay	Đặt thành thiếu

Quy tắc chống rò rỉ

Chia trước, biến đổi sau · trung vị, trung bình, độ lệch chuẩn, ngưỡng cắt chỉ học trên **train** · pipeline `fit` trên train, val/test chỉ `transform`

Chọn đặc trưng: 151 → 57

Mỗi cột đi qua các bộ lọc theo thứ tự cố định; khớp đầu tiên sẽ loại cột



Kiểm chứng rò rỉ

ROC-AUC từng cột trên train.
Cột hợp lệ tốt nhất: `sub_grade` **0.6565**.

Cột sau khi vay mạnh hơn hẳn:
`last_fico_range_low` 0.9074
`recoveries` 0.9054
`total_rec_prncp` 0.8280

Tạo đặc trưng và tiền xử lý: 57 → 153

Tạo biến mới, bỏ biến trùng, rồi điền thiếu, chuẩn hóa và one-hot trong một pipeline

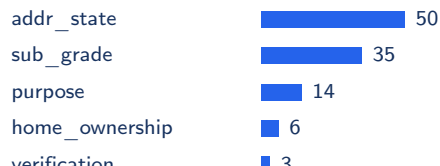
57 ứng viên → **+1** issue_date (mốc) → **+6** biến mới → **−14** trùng và tương quan cao → **50** 45 số + 5 phân loại →

153 ma trận cuối

6 BIẾN MỚI

`fico_avg`: trung bình khoảng FICO
`credit_history_years`: số năm lịch sử tín dụng
`loan_to_income`: vay / thu nhập
`log_annual_inc`, `log_revol_bal`: giảm lệch phải
`emp_length_years`: chữ → số

CỘT ONE-HOT (TỔNG 108)



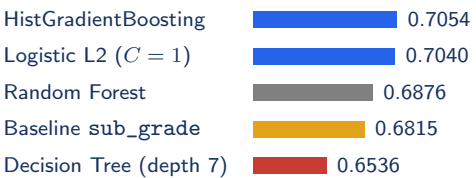
45 biến số: điền trung vị + StandardScaler

CHƯƠNG 3 · BƯỚC 7 · NOTEBOOK 03

Huấn luyện và kiểm định mô hình

5 mô hình được tinh chỉnh bằng TimeSeriesSplit; so sánh trên tập validation

ROC-AUC TRÊN VALIDATION (trục bắt đầu từ 0.60)



QUÁ KHỚP (AUC TRAIN − AUC VAL)

Random Forest $+0.018$ · HistGB $+0.004$ · Logistic -0.017

BOOTSTRAP 95% CI · ΔAUC SO VỚI BASELINE

HistGB [+0.021, +0.027]
Logistic L2 [+0.020, +0.025]
Random Forest [+0.002, +0.010]
Decision Tree [−0.033, −0.023]

CHƯƠNG 3 · BƯỚC 8 · NOTEBOOK 03

Đánh giá Out-of-Time trên tập test và kết luận

Tập test chỉ dùng một lần: 88,669 khoản vay, 2015-10 đến 2015-12

	ROC-AUC	Gini	KS
Baseline `sub_grade`	0.6818	36.4%	26.5%
Logistic L2 ĐƯỢC CHỌN	**0.7039**	40.8%	29.9%
HistGradientBoosting	0.7055	41.1%	30.0%

HISTGB − LOGISTIC (CI 95%)

$[-0.0002,\ +0.0031]$ → chứa 0: chưa phân biệt được

Quyết định: Logistic L2

✓ Hơn baseline $+0.022$ AUC

✓ Ngang HistGB

✓ Không quá khớp, huấn luyện nhanh

✓ Mỗi hệ số dễ giải thích

Ablation: mô hình không có sub_grade

Bỏ hạng của Lending Club: 153 → 118 đặc trưng. Mô hình còn tốt hơn baseline không?

ROC-AUC TRÊN TEST (trục từ 0.66)

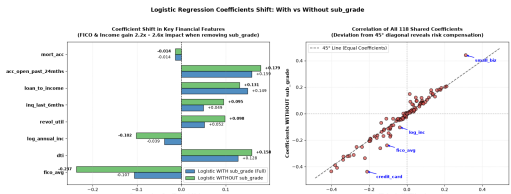
Logistic L2 (có sub_grade) 0.7039

Logistic L2 (không sub_grade) 0.6879

Baseline sub_grade 0.6818

+0.0075 không sub_grade so với baseline
CI 95% [+0.003, +0.012]

+0.0150 giá trị bổ sung của sub_grade
CI 95% [+0.013, +0.017]



sub_grade hấp thụ tín hiệu rủi ro; khi bỏ đi, trọng số quay về FICO, thu nhập và mức dùng tín dụng ($1.2\times - 2.6\times$).

Mô hình tinh gọn và thẻ điểm tín dụng

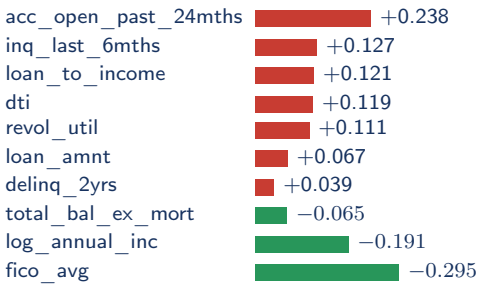
12 đặc trưng cốt lõi, không có `sub_grade`, quy đổi thành điểm kiểu 300 – 850

153 → 30
cột (-80%)

0.673
ROC-AUC test (Gini 34.6%)

494 – 757
khoảng điểm (validation)

TRỌNG SỐ 10 BIẾN SỐ



QUY ĐỔI ĐIỂM

Điểm cơ sở: 600 tại odds 5 : 1
PDO: 20 điểm
Ngưỡng ví dụ: 615
Điểm cao = rủi ro thấp

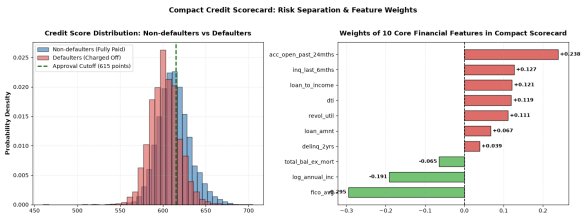
2 BIẾN PHÂN LOẠI

`home_ownership`, `purpose`

Ít đầu vào hơn: thu thập dữ liệu rẻ hơn, dễ giải thích cho cán bộ tín dụng. Các hằng số 600, PDO 20 là quy ước tự chọn.

Phân phối điểm: người trả tốt và người vỡ nợ

Thẻ điểm tinh gọn 12 đặc trưng · tập test, 88,669 khoản vay



TỶ LỆ VỠ NỢ THEO DẢI ĐIỂM

(trung bình 14.8%)

< 590 Từ chối	30.2%
590–614 Thẩm định	17.3%
615–639 Duyệt	8.7%
≥ 640 Duyệt	3.3%

9× chênh lệch tỷ lệ vỡ nợ: dải thấp nhất so với cao nhất

25.1% KS trên test

Kết luận chung

1. **Vượt mốc có sẵn, ở mức vừa phải.** AUC test: baseline 0.6818, Logistic 0.7039, HistGB 0.7055; khoảng tin cậy trên validation không chứa 0.
2. **Phức tạp hơn chưa chắc tốt hơn.** HistGB và Logistic ngang nhau; rừng ngẫu nhiên cải thiện ít hơn; cây độ sâu 7 kém hơn baseline.
3. `sub_grade` **hấp thụ tín hiệu.** Bỏ `sub_grade`: AUC test 0.6879 ($+0.0061$ so với baseline); hệ số FICO và thu nhập tăng khoảng gấp đôi.
4. **Thẻ điểm tinh gọn rẻ nhưng yếu hơn**, tuy vậy phân tầng rủi ro từ 30.2% xuống 3.3% tỷ lệ vỡ nợ thực.
5. Mọi con số đều do code in ra trên dữ liệu thật; kết quả không như kỳ vọng được báo cáo đúng như vậy.

Hướng phát triển

Hạn chế

- Chỉ khoản vay 36 tháng, 2012–2015; cửa sổ test 3 tháng
- Lưới RF và HistGB chạm biên
- CI bootstrap chỉ phản ánh nhiễu mẫu validation
- Val AUC $>$ Train AUC (Baseline, Logistic): quan sát được, chưa giải thích
- Chưa có calibration, ngưỡng và phân tích chi phí
- Hằng số thẻ điểm (600, PDO 20) là quy ước

Hướng phát triển

- Mở rộng hoặc ngẫu nhiên hóa việc tìm siêu tham số
- Đánh giá nhiều cửa sổ thời gian; kiểm tra dataset shift [1]
- Xử lý các cột `mths_since_...` bằng biến chỉ báo thiếu
- Calibration và ngưỡng theo chi phí
- Khoản vay 60 tháng bằng phân tích sống còn
- Kiểm tra tính công bằng và độ ổn định

PHỤ LỤC

Các thước đo đánh giá

ROC-AUC: xác suất mô hình cho khoản vỡ nợ điểm cao hơn khoản trả đủ

Gini $= 2\times$ AUC -1: thước đo chuẩn trong rủi ro tín dụng

KS: khoảng cách lớn nhất giữa đường tích lũy của nhóm vỡ nợ và nhóm trả đủ, $\max(\mathrm{TPR} - \mathrm{FPR})$

Không cần chọn ngưỡng xác suất: cả ba thước đo đều đo khả năng xếp hạng. Cùng một hàm dùng cho mọi mô hình và mọi tập dữ liệu.

NB03 cell 5

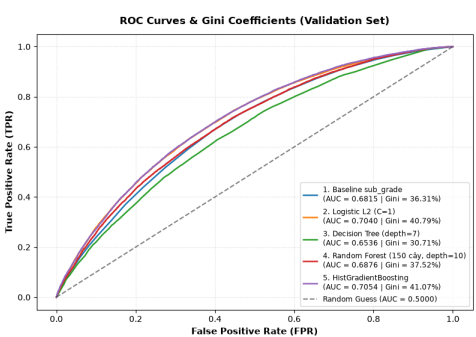
```
def calculate_metrics(y_true, proba):
  auc = roc_auc_score(y_true, proba)
  gini = 2 * auc - 1
  fpr, tpr, _ = roc_curve(y_true, proba)
  ks = np.max(tpr - fpr)
  return auc, gini, ks
```

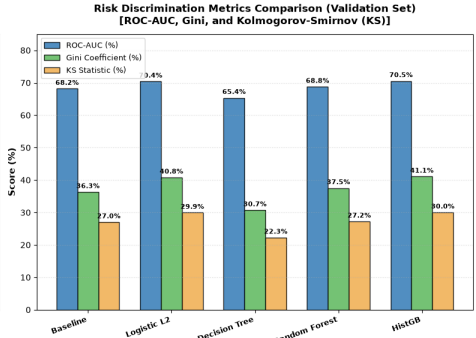
Tinh chỉnh siêu tham số và Train so với Validation

Mô hình	Lưới tham số	Tốt nhất	CV AUC
Logistic L2	$C \in \{0.001 \dots 10\}$	$C = 1.0$	0.6855
Decision Tree	max_depth 3–10	depth $= 7$	0.6355
Random Forest	trees 50/100/150, depth 6/8/10, leaf 30/50/60	150, 10, 50	0.6741
HistGradientBoosting	lr 0.05–0.20, depth 4–10, iter 50–150	0.05, 10, 150	0.6852

Mô hình (val = 92,631 khoản)	AUC train	AUC val	Chênh	Gini val	KS val
Baseline sub_grade	0.6565	0.6815	-0.0250	36.31%	27.02%
Logistic L2 ($C = 1$)	0.6873	0.7040	-0.0167	40.79%	29.94%
Decision Tree (depth 7)	0.6541	0.6536	$+0.0006$	30.71%	22.25%
Random Forest (150, depth 10)	0.7060	0.6876	$+0.0184$	37.52%	27.21%
HistGradientBoosting	0.7096	0.7054	$+0.0042$	41.07%	30.02%

Đường cong ROC và bootstrap





Bootstrap $B = 1{,}000$ mẫu có hoàn lại trên validation; nếu CI 95% của ΔAUC không chứa 0 thì mức cải thiện là thật.

Mô hình	ΔAUC so với baseline	CI 95%
Logistic L2	$+0.0225$	$[+0.0196, +0.0253]$
Decision Tree	-0.0280	$[-0.0329, -0.0233]$
Random Forest	$+0.0061$	$[+0.0024, +0.0102]$
HistGradientBoosting	$+0.0238$	$[+0.0206, +0.0270]$

Tài liệu tham khảo I

H. Qian, B. Wang, P. Ma, L. Peng, S. Gao, and Y. Song, "Managing dataset shift by adversarial validation for credit scoring," arXiv preprint arXiv:2112.10078, 2021.

C. Serrano-Cinca, B. Gutiérrez-Nieto, and L. López-Palacios, "Determinants of default in P2P lending," *PLoS ONE*, vol. 10, no. 10, p. e0139427, 2015.

M. Malekipirbazari and V. Aksakalli, "Risk assessment in social lending via random forests," *Expert Systems with Applications*, vol. 42, pp. 4621–4631, 2015.

N. Siddiqi, *Intelligent Credit Scoring: Building and Implementing Better Credit Risk Scorecards*, 2nd ed., ser. Wiley and SAS Business Series. Hoboken, NJ: John Wiley & Sons, 2017.

N. George, "Lending club loan data (accepted and rejected loans, 2007–2018)," Kaggle dataset (user `wordsforthewise`), https://www.kaggle.com/datasets/wordsforthewise/lending-club, accessed 2026.

D. J. Hand and W. E. Henley, "Statistical classification methods in consumer credit scoring: a review," *Journal of the Royal Statistical Society: Series A*, vol. 160, no. 3, pp. 523–541, 1997.

F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and É. Duchesnay, "Scikit-learn: machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

Tài liệu tham khảo II

- J. H. Friedman, "Greedy function approximation: a gradient boosting machine," *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.
- L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: a highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems 30*, 2017, pp. 3146–3154.
- B. Efron, "Bootstrap methods: another look at the jackknife," *The Annals of Statistics*, vol. 7, no. 1, pp. 1–26, 1979.
- T. Fawcett, "An introduction to ROC analysis," *Pattern Recognition Letters*, vol. 27, no. 8, pp. 861–874, 2006.
- F. J. Massey, "The Kolmogorov–Smirnov test for goodness of fit," *Journal of the American Statistical Association*, vol. 46, no. 253, pp. 68–78, 1951.

Xin cảm ơn

Thầy cô và các bạn đã lắng nghe